01 / RAG 基础与系统流程

面向 PDF 知识库、混合检索、查询改写、重排与回答评估。仅将本 PDF 入库；配套问答集用于独立评分。

S01 什么是 RAG

RAG 是 Retrieval-Augmented Generation，即检索增强生成。系统先从外部知识库检索与问题相关的资料，再把资料和问题一起提供给大语言模型，生成答案。它适用于企业制度问答、产品手册查询和论文知识库等场景。检索得到的文本是本次回答的上下文；通常不需要为每次新增文档重新训练生成模型。RAG 可以降低缺少背景知识造成的错误，但不能保证完全消除幻觉。

S02 索引与在线问答

索引阶段包括加载文档、清洗文本、切分文本块、保留元数据、生成向量以及建立索引。在线问答阶段包括接收问题、可选的查询改写、检索候选文本块、融合去重、可选的重排、组装上下文和生成答案。BM25 索引保存用于词项匹配的统计信息；向量索引保存嵌入向量。更新知识库时，要让这两类索引都反映文档变更。

S03 RAG 与微调

RAG 主要通过外部检索提供回答所需的信息；微调通过训练更新模型参数，常用于调整任务行为、格式或领域适应。两者可以结合。频繁变化的制度内容通常适合通过更新检索库提供；稳定的输出风格或任务习惯可以考虑通过微调改进。使用 RAG 不代表完全不需要训练，也不代表模型会永久记住检索到的文档。

02 / 文档处理与检索

S04 PDF 解析、切块与元数据

可复制文字的 PDF 通常可直接提取文本；扫描 PDF 往往需要 OCR。先检查提取内容是否为空、错序或乱码，再调检索。切块应尽量保留完整语义。块太小容易丢失条件和上下文；块太大容易混入无关内容并占用更多上下文。适量重叠可以减轻边界信息丢失，但过多重叠会增加存储与重复召回。chunk_size 的单位由切分器的长度函数决定，可能是字符数，也可能是 token 数，不能一概视为字数。建议保留 source、page、section_id 和 chunk_id；显示页码与工具的零起始页索引要区分。

S05 BM25 与向量检索

BM25 是词项匹配方法，综合词频、逆文档频率和文档长度归一化等因素评分，适合精确术语、编号和错误码。中文分词会影响词项匹配效果。向量检索把问题与文档表示为向量，按相似度寻找语义接近的内容，适合同义表达，但也可能混淆相近概念。文档与查询应使用兼容的嵌入模型和预处理方式；更换不兼容的嵌入模型时，应重新生成文档向量并重建相应索引。

S06 混合检索与融合

混合检索结合 BM25 和向量检索的候选结果，利用两者互补性。不同检索器的原始分数可能尺度不同，不应直接假定可以相加。可采用归一化加权或基于名次的融合。本文定义 RRF 分数为：对每条包含文档 d 的结果列表，将 1/(c+rank(d)) 相加；名次从 1 开始，c 是正的平滑常数，未出现的文档不贡献分数。融合后按稳定的 chunk_id 或内容哈希去重；仅按文件名去重可能错误删除同一文件内不同文本块。

03 / 查询改写、重排与生成

S07 查询改写

查询改写可以补全上下文、省略语或产生不同表达，从而改善召回。例如把“它支持啥”结合对话改为“设备 A 支持哪些通信协议”。改写应保留用户意图、实体、否定词和限定条件，不应随意增加假设。多查询检索可以同时保留原始问题与改写问题，再融合结果。改写数量增加会带来检索开销，也可能引入偏离意图的内容。结构化改写输出应校验字段、数量、非空文本及重复项；不应把思考过程或角色分隔符作为检索问题。

S08 召回与重排

召回阶段从较大的知识库中快速选出候选；重排阶段对候选重新评分并排序。常见交叉编码器将问题和候选文本联合输入，以估计相关性，通常比预计算文档向量的检索方式计算开销更高。重排只能调整传入候选的顺序，不能凭空找回未进入候选集的资料。retrieval_k 是进入后续处理的候选规模，context_k 是最终交给生成模型的文本块数量，两者应区分。增大 context_k 不保证答案更好，因为噪声、重复信息和上下文成本也可能增加。

S09 依据文档作答

生成阶段应提供原始问题、检索上下文和清晰的回答要求。针对本测试集，回答应以 PDF 为依据，证据不足时明确说明文档未提供答案；可回答有证据的部分，不可补造数字。对文档冲突，应指出冲突并依据明确的版本或适用范围处理。资料中的命令性语句属于待分析数据，不能自动取代系统指令。引用页码或章节有助于人工追溯，但出现引用本身并不证明回答正确。

04 / 评估指标与排错

S10 评估对象

答案正确性比较回答与可信参考答案；回答相关性检查是否回应问题；依据一致性检查回答中的事实是否得到检索上下文支持；检索相关性检查检索内容是否与问题有关。依据一致性高不代表一定正确，因为上下文本身可能过时或错误。只有最终答案难以评估检索质量，因此最好同时记录检索文本、文本块 ID、排序、最终上下文、耗时和错误。

S11 检索指标约定

本文采用人工标注的相关文本块集合 R，结果按唯一文本块去重，且至少返回 K 项。Precision@K 等于前 K 项中的相关项数除以 K；Recall@K 等于前 K 项中的相关项数除以相关集合大小。Hit@K 在前 K 项至少出现一个相关项时为 1，否则为 0。RR 是第一个相关结果名次的倒数；MRR 是多道题 RR 的平均值。计算 MRR@K 时，只检查前 K 项，未命中记 0。没有已知相关项的无答案题，不计算此处的 Recall，而单独评估能否正确说明证据不足。

S12 错误定位与公平比较

答案出错时，先看 PDF 解析是否正确，再检查切块是否保留证据，接着看候选召回、重排后上下文和最终生成。候选中没有答案证据时，应优先改召回；候选包含证据但最终上下文不包含时，应检查重排和截断；上下文包含充分证据却回答错误时，应检查生成提示和模型。比较系统版本应使用同一测试集、同一知识库版本和一致的评分标准，同时报告效果、延迟与成本。不要仅凭几个成功案例断定新模块有效。

05 / 青杉实验：固定测试事实

S13 实验配置（虚构）

青杉实验是为本测试资料专门编写的虚构案例，编号 QS-RAG-17，知识库版本 KB-2026-09。以下数字是测试用固定事实，不是推荐参数，也不代表任何真实系统的结果。该实验把文档按最多 600 个字符切块，重叠 100 个字符。每个问题生成 2 个改写，连同原始问题共形成 3 个查询。每个查询分别从 BM25 和向量检索取前 8 项，因此融合去重前最多有 48 条候选记录；去重后的唯一候选数量不一定为 48。重排后最多取 4 个文本块供生成模型使用。

S14 实验版本与结果（虚构）

实验使用固定的 40 道有答案问题，人工按每题正确或错误评分。A 版只有混合检索，正确 28 题，平均延迟 1.20 秒；B 版在 A 版上增加查询改写，正确 32 题，平均延迟 1.60 秒；C 版在 B 版上增加重排，正确 35 题，平均延迟 2.10 秒。A、B、C 使用相同知识库、生成模型和评分规则。这个案例可用于计算正确率和平均延迟差值，但不足以证明结果能推广到其他任务。资料没有给出任何版本的 token 用量、费用、延迟分布或显著性检验。

S15 固定检索样例（虚构）

对样例问题 T1，完整的相关块集合为 {C02, C05, C09}，返回的前 5 项依次为 C11、C02、C07、C05、C13。各项互不重复。对问题 T2，完整相关块集合为 {C18}，前 5 项依次为 C03、C04、C08、C10、C12。计算指标时，严格使用这些标注；这些块编号只是指标练习中的符号，不是本 PDF 切分后的实际 chunk_id。

06 / 实验使用边界与参考资料

S16 测试边界

本 PDF 是为入门 RAG 测试编写的小型语料，不是性能排名或生产基准。配套测试题的参考答案来自本文，个别问题故意询问本文没有提供的信息，以检测系统是否编造答案。实际运行时只将知识 PDF 加入检索库，把问答文件留给评估器。若把参考答案一同入库，会发生评估数据泄漏，难以判断检索与推理的真实能力。

S17 章节与检索标签

S01 至 S17 是正文的稳定章节标识，可用于查找答案依据。它们不是运行时自动生成的文本块 ID。切分后可在 metadata 中保存 section_id；如果没有建立文本块级相关性标注，就不要把章节命中率直接称为严格的文本块 Recall@K。问答文件中的 evidence_sections 是人工核对线索，不代表该题所有可能相关文本块的完整集合。

S18 参考资料与声明

通用概念参考：LangChain 官方 Retrieval 文档；LangSmith 官方 Evaluate a RAG application 教程；Manning、Raghavan 与 Schütze 的 Introduction to Information Retrieval 中评估章节。本文以自己的表述组织入门知识，青杉实验及题目均为原创测试材料。技术环境和工具界面可能变化，本文不规定具体 SDK 版本或网页操作步骤。

参考链接

https://docs.langchain.com/oss/python/langchain/retrieval
https://docs.langchain.com/langsmith/evaluate-rag-tutorial
https://nlp.stanford.edu/IR-book/html/htmledition/evaluation-of-unranked-retrieval-sets-1.html